

UNIVERSIDADE ESTADUAL DE CAMPINAS

RENATO LOPES MOURA RA163050

Estudo sobre Inferência Fuzzy baseada em medidas de
subsethood

CAMPINAS

2016

Sumário

1	Conceitos matemáticos	3
2	Inferência baseada em similaridade x subsethood	5
3	Aplicação em previsão de séries temporais	6
3.1	A série caótica de Mackey-Glass	6
3.2	Aprendizagem de regras fuzzy	6
3.3	Resultados	6
4	Experimentos	10
4.1	Caso 1	10
4.2	Caso 2	13
4.3	Caso 3	16
4.4	Caso 4	19
4.5	Caso 5	22

1 Conceitos matemáticos

Uma medida de *subsethood* avalia o grau de "inclusão" de um conjunto *fuzzy* em outro, em outras palavras é uma generalização do operador \subseteq da teoria de conjuntos clássica. Neste trabalho adotaremos a seguinte definição de medida de *subsethood* proposta por Fan *et al.*[1]:

Definição 1. Seja uma função $S : \mathcal{F}(X) \times \mathcal{F}(X) \rightarrow [0, 1]$. $S(A, B)$ é uma medida de *subsethood* se para $A, B, C \in \mathcal{F}(X)$ temos:

1. $S(A, B) = 1 \Leftrightarrow A \subseteq B$
2. $S(X, \emptyset) = 0$
3. Se $A \subseteq B \subseteq C$, então $S(C, A) \leq S(B, A)$ e $S(C, A) \leq S(C, B)$

Um exemplo é a medida de *subsethood* de Kosko [3] definida da seguinte forma:

$$S_k(A, B) = \frac{\int_{x \in X} \min(\mu_A(x), \mu_B(x))}{\int_{x \in X} \mu_A(x)}$$

As medidas de *subsethood* S_p^\cap (meet) e S_p^\cup (join) são definidas da seguinte forma:

$$\begin{aligned} S_p^\cap(A, B) &= I(v_p(A), v_p(A \cap B)), \\ S_p^\cup(A, B) &= I(v_p(A \cup B), v_p(B)) \end{aligned}$$

Onde I representa uma implicação fuzzy e v_p é uma função $\mathcal{F}(X) \rightarrow [0, 1]$ com $p \in (0, +\infty)$.

Neste trabalho, utilizaremos a implicação de Goguen:

$$I(x, y) = \begin{cases} 1 & \text{se } x = 0 \\ \min(1, \frac{y}{x}) & \text{se } x > 0 \end{cases}$$

e a seguinte função para v_p :

$$v_p(A) = \sum_{i=1}^k \frac{1 - \cos(\frac{\pi[\mu_A(x_i)]^p}{2k})}{2k}, \quad X = \{x_1, \dots, x_k\}$$

Outra importante relação entre conjuntos *fuzzy* é a medida de similaridade, que generaliza a igualdade de conjuntos da teoria de conjuntos clássica. Neste trabalho utilizaremos a definição mais comum de medida de similaridade encontrada na literatura.

Definição 2. Uma função $SM : \mathcal{F}(X) \times \mathcal{F}(X) \rightarrow [0, 1]$ é dita uma medida de similaridade se SM satisfaz as seguintes propriedades para todos $A, B, C \in \mathcal{F}(X)$:

1. $SM(A, B) = SM(B, A)$
2. $SM(X, \emptyset) = 0$
3. $SM(A, A) = 1$
4. Se $A \subseteq B \subseteq C$, então $SM(A, B) \geq SM(A, C)$ e $SM(B, C) \geq SM(A, C)$

Uma das medidas de similaridade mais comumente utilizadas é a razão de Jaccard [2], definida pela seguinte expressão:

$$SM(A, B) = \frac{\int_{x \in X} \min(\mu_A(x), \mu_B(x))}{\int_{x \in X} \max(\mu_A(x), \mu_B(x))}$$

para $A, B \in \mathcal{F}(X)$.

2 Inferência baseada em similaridade x subsethood

3 Aplicação em previsão de séries temporais

3.1 A série caótica de Mackey-Glass

A série temporal de Mackey-Glass[5] é modelada pela seguinte equação diferencial:

$$\frac{dx(t)}{dt} = \beta \frac{x(t-\tau)}{1+x^n(t-\tau)} - \gamma x(t)$$

Neste trabalho serão utilizados os parâmetros $\beta = 0.2$, $\gamma = 0.1$, $n = 10$ e $\tau = 30$, de forma que nestas condições a série apresenta um comportamento caótico. O estado inicial da série, ou seja, os valores de $x(t)$ para $t \in [-\tau, 0]$ é definido como $x(t) = 1.2$.

3.2 Aprendizagem de regras fuzzy

Utilizando o procedimento descrito em [6] é possível obter uma base de regras *fuzzy* utilizando uma certa quantidade de pontos (antecedentes) para prever os pontos seguintes (consequentes).

3.3 Resultados

Definição 3. Um *modificador fuzzy* m sobre X é uma aplicação do tipo:

$$m : \mathcal{F}(X) \rightarrow \mathcal{F}(X)$$

tal que m é dito:

1. *Expansivo* se, para todo $A \in \mathcal{F}(X)$, $A \subseteq m(A)$, ou seja, $\mu_A(x) \leq \mu_{m(A)}(x)$, $\forall x \in X$;
2. *Restritivo* se, para todo $A \in \mathcal{F}(X)$, $A \supseteq m(A)$, ou seja, $\mu_A(x) \geq \mu_{m(A)}(x)$, $\forall x \in X$;

Proposição 1. Considere o seguinte procedimento para construção de números fuzzy modificados:

1. Centrar A em torno de 0;
2. Adicionar c a ambos os lados de $\text{supp}(A')$;
3. Calcular $f = \frac{\text{width}(\text{supp}(A'_c))}{\text{width}(\text{supp}(A'))}$;
4. Multiplicar todos os α -cortes por f ;
5. Transladar o resultado de volta.

Isto deve funcionar para todos os números fuzzy, menos números fuzzy crisp, que podem ser vistos como números fuzzy triangulares. Para $r \in \mathbb{R}$, podemos definir $r^c = (r - c; r; r + c)$.

Exemplo 1. Seja o seguinte número fuzzy $A \in \mathcal{F}(\mathbb{R})$:




Figure 1: Número fuzzy a ser modificado.

Com função de pertinência dada por:

$$\mu_A(x) = \begin{cases} x - 2 & \text{se } 2 < x \leq 3 \\ 4 - x & \text{se } 3 < x \leq 4 \\ 0 & \text{c.c.} \end{cases}$$

E α -cortes dados por:

$$A^\alpha = [\alpha + 2, -\alpha + 4]$$

Aplicando o procedimento descrito na Proposição 1, temos:

- **Passo 1:** Centrar A em torno de 0.




Figure 2: Número fuzzy A' centrado em 0.

- **Passo 2:** Adicionar c a ambos os lados de $\text{supp}(A')$. Considerando $c = 1$, temos:

$$\text{supp}(A') = [-1, 1] \Rightarrow \text{supp}(A'_c) = [-2, 2]$$

- **Passo 3:** Calcular $f = \frac{\text{width}(\text{supp}(A'_c))}{\text{width}(\text{supp}(A'))}$.

$$f = \frac{\text{width}(\text{supp}(A'_c))}{\text{width}(\text{supp}(A'))} = \frac{\text{width}([-2, 2])}{\text{width}([-1, 1])} = \frac{4}{2} = 2$$

- **Passo 4:** Multiplicar todos os α -cortes por f .

$$\begin{aligned} B'^\alpha &= f \cdot A'^\alpha = 2 \cdot A'^\alpha \\ &= 2 \cdot [\alpha - 1, -\alpha + 1] \\ &= [2\alpha - 2, -2\alpha + 2] \end{aligned}$$

- **Passo 5:** Transladar o resultado de volta.

Como resultado temos o seguinte número fuzzy $B \in \text{mathcal{F}}(\mathbb{R})$:




Figure 3: Número fuzzy modificado B .

Com função de pertinência dada por:

$$\mu_B(x) = \begin{cases} \frac{x-1}{2} & \text{se } 1 < x \leq 3 \\ \frac{5-x}{2} & \text{se } 3 < x \leq 5 \\ 0 & \text{c.c.} \end{cases}$$

E α -cortes dados por:

$$B^\alpha = [2\alpha + 1, -2\alpha + 5]$$

4 Experimentos

4.1 Caso 1

Entrada triangular quase discreta (3.4,3.5,3.6)

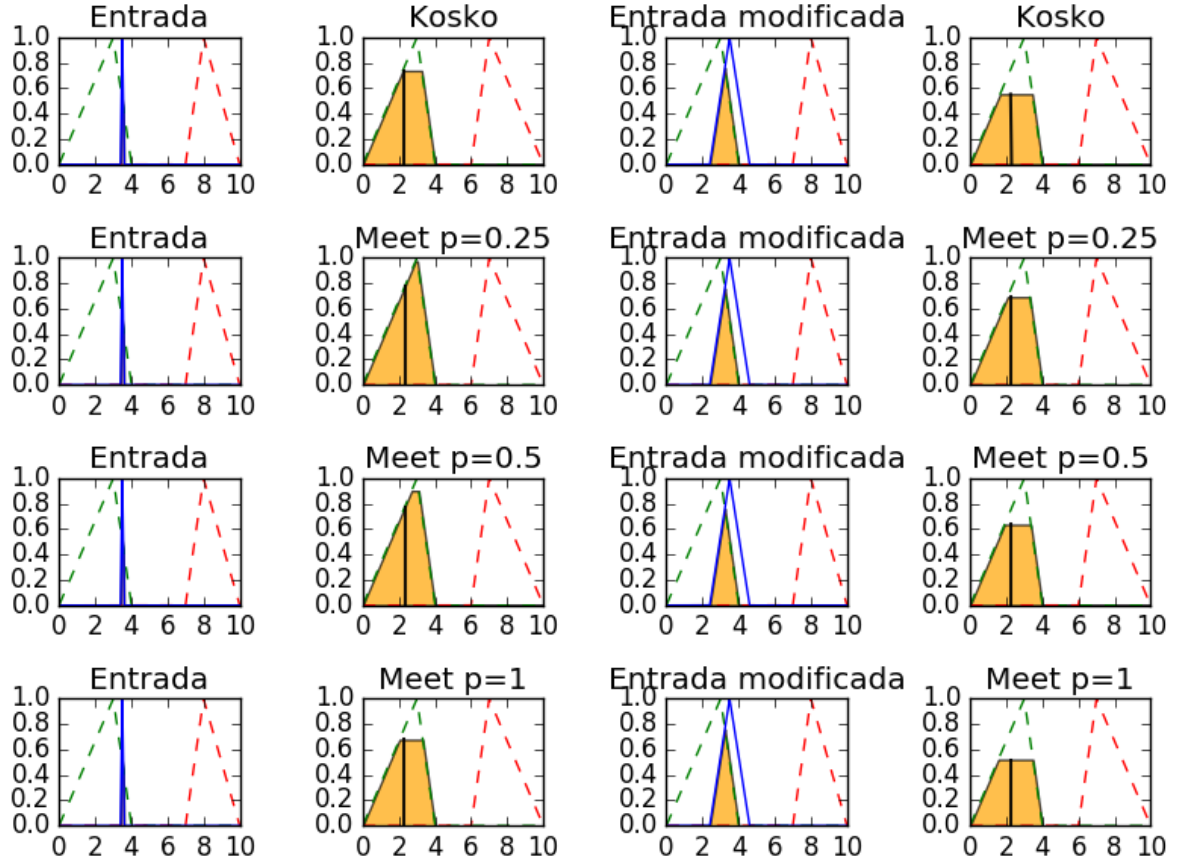


Figure 4: Resultados do caso 1 para $c = 1$




Figure 5: Resultados do caso 1 para $c = 2$

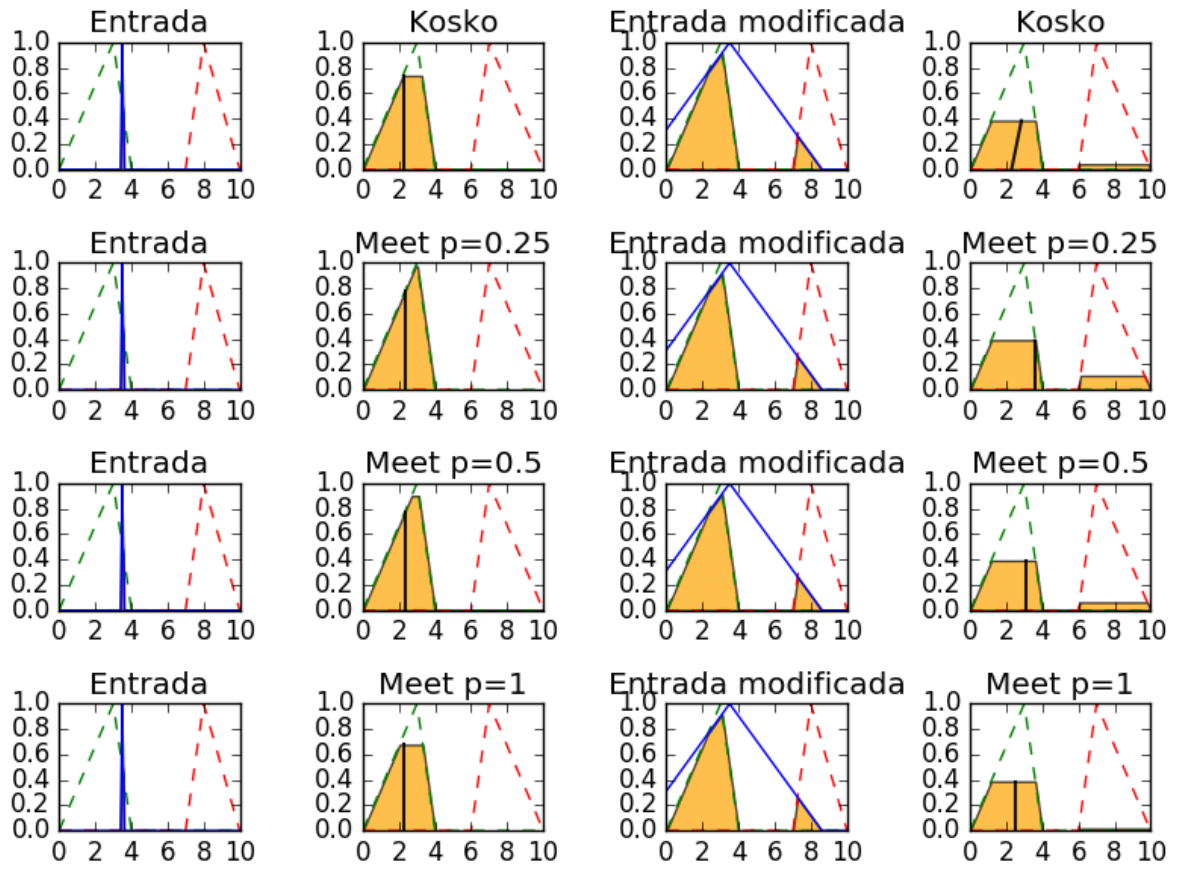


Figure 6: Resultados do caso 1 para $c = 5$

4.2 Caso 2

Entrada triangular quase igual ao antecedente (0.0,3.3,4.0)




Figure 7: Resultados do caso 2 para $c = 1$




Figure 8: Resultados do caso 2 para $c = 2$




Figure 9: Resultados do caso 2 para $c = 5$

4.3 Caso 3

Entrada triangular com pouca intersecção (3.8,4.0,5.0)




Figure 10: Resultados do caso 3 para $c = 1$




Figure 11: Resultados do caso 3 para $c = 2$




Figure 12: Resultados do caso 3 para $c = 5$

4.4 Caso 4

Entrada triangular sem intersecção mas próxima de um dos antecedentes (4.0,4.5,5.0)

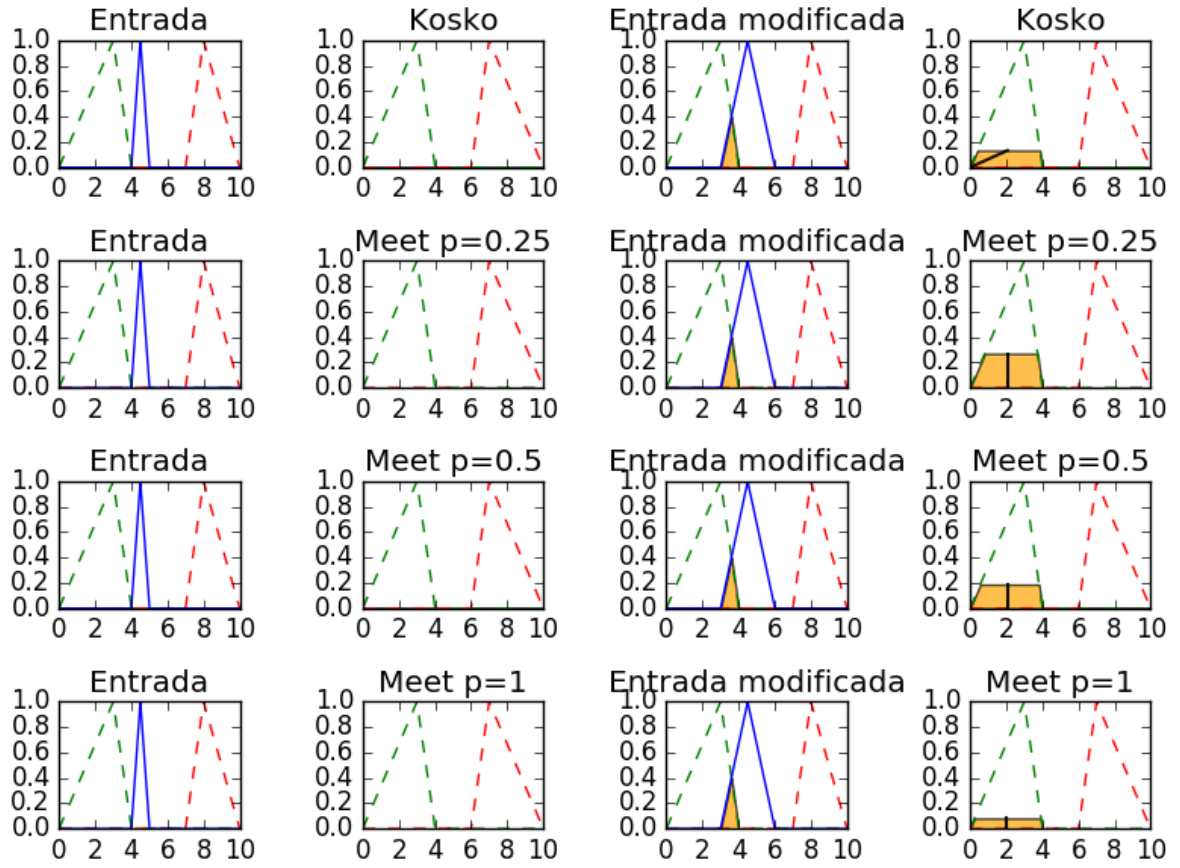


Figure 13: Resultados do caso 4 para $c = 1$




Figure 14: Resultados do caso 4 para $c = 2$

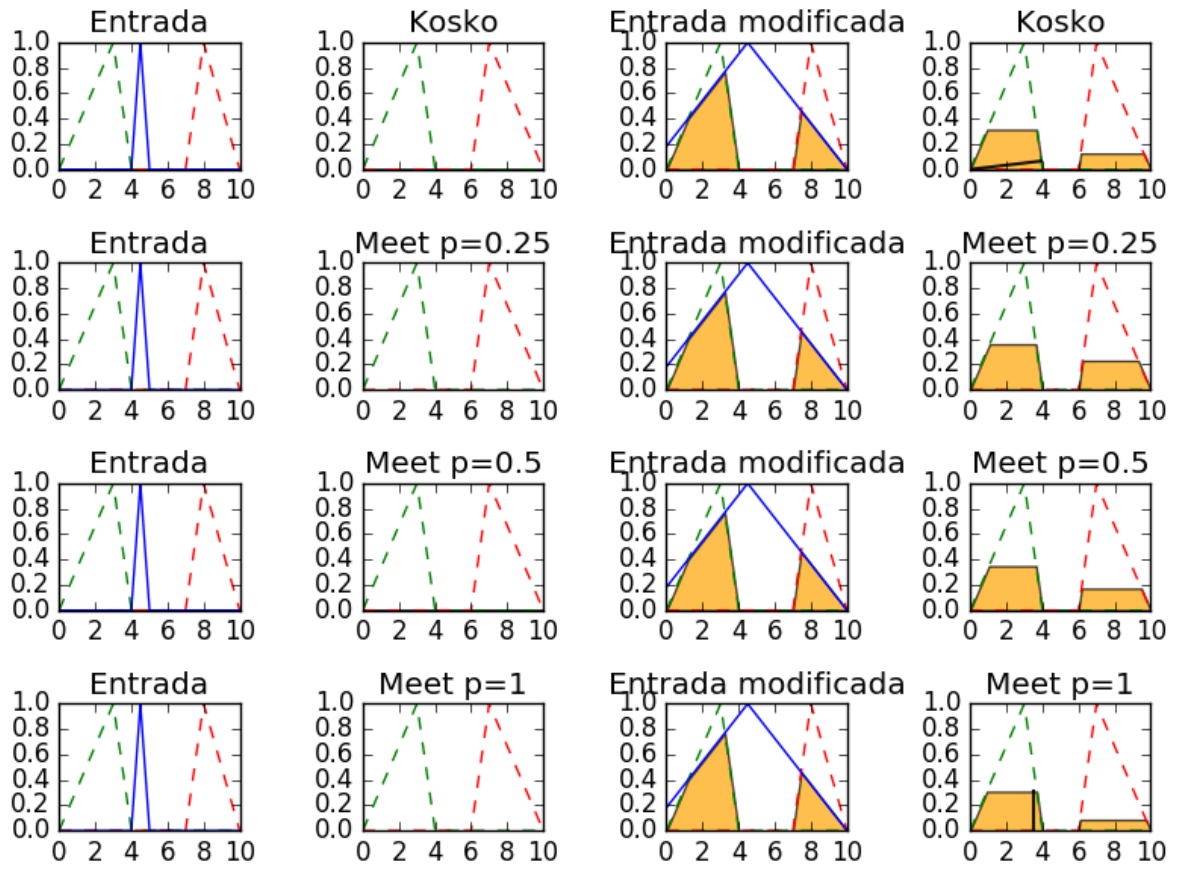


Figure 15: Resultados do caso 4 para $c = 5$

4.5 Caso 5

Entrada triangular equidistante dos antecedentes (5.0,5.5,6.0). Obs: notar que os antecedentes não possuem o mesmo tamanho.

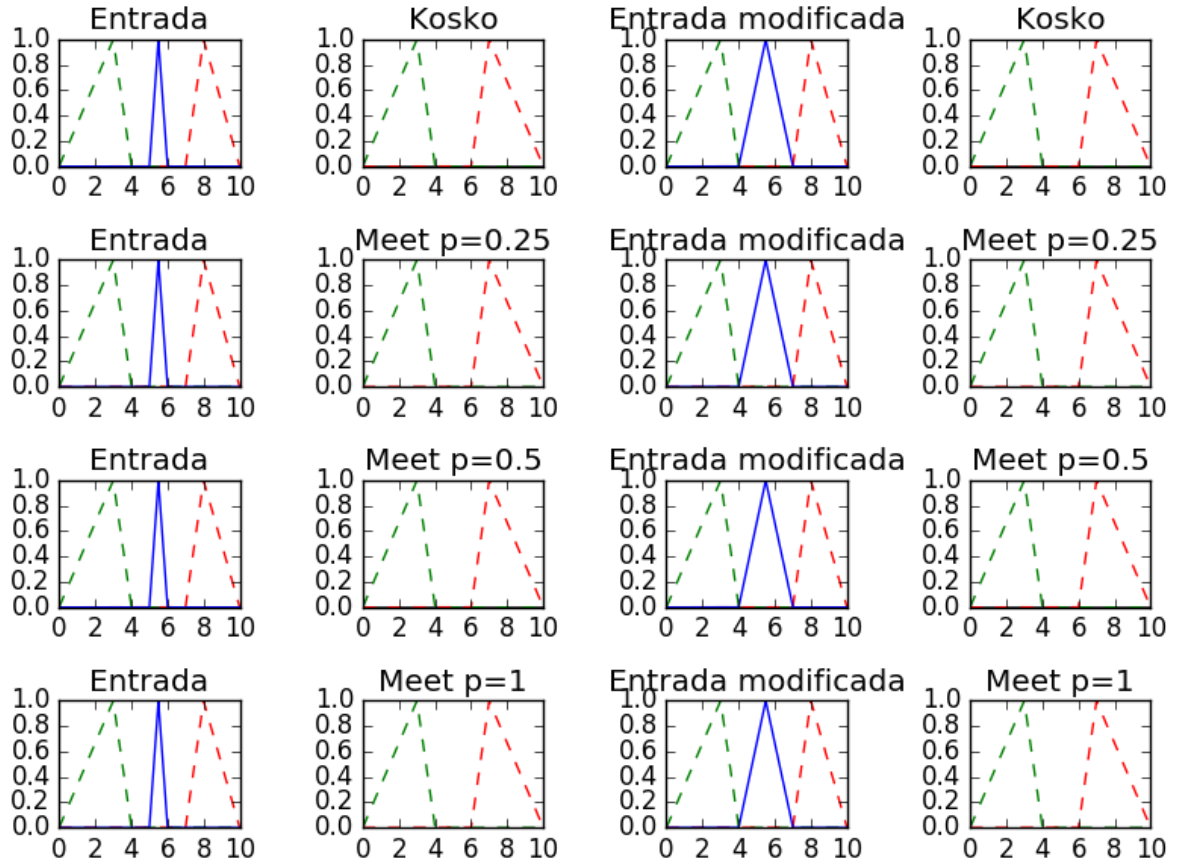


Figure 16: Resultados do caso 5 para $c = 1$




Figure 17: Resultados do caso 5 para $c = 2$




Figure 18: Resultados do caso 5 para $c = 5$

References

- [1] J. Fan, W. Xie, and J. Pei. *Subsethood measure: new definitions*. Fuzzy Sets and Systems 106.2 (Sept. 1999), pp. 201-209.
- [2] P. Jaccard, *Nouvelles recherches sur la distribution florale*, (1908).
- [3] B. Kosko, *Fuzziness versus probability*. Int. J. General Syst., vol. 17, pp. 211-240, (1990).
- [4] Esmi, Estevao; Sussner, Peter ; Bustince SOLA, Humberto ; Fernandez, Javier. *θ -Fuzzy Associative Memories (θ -FAMs)*. IEEE Transactions on Fuzzy Systems, v. 23, p. 1-1, (2015).
- [5] M.C. Mackey, L. Glass, *Oscillation and chaos in physiological control systems*. Science, Vol 197: 287-289, 1977
- [6] L. Wang and J. M. Mendel, *Generating fuzzy rules by learning from examples*. IEEE Trans. Syst., Man, Cybern., vol. 22, no. 6, pp. 1414-1427, (1992).